

FTL: TRANSFERENCIA DE CONOCIMIENTO ENTRE MODALIDADES FLAIR Y T1W PARA LA CLASIFICACIÓN DE ESCLEROSIS MÚLTIPLE

Álvaro Pastor García, Dmytro Morgun, Jorge Serrano Jiménez

Universidad de Málaga
ETSI Informática

ABSTRACT

Este proyecto evalúa un escenario de *Federated Transfer Learning* (FTL) aplicado a la clasificación binaria de Esclerosis Múltiple (EM) frente a controles sanos mediante imágenes de resonancia magnética. A diferencia del Aprendizaje Federado Horizontal clásico, los hospitales participantes no comparten exactamente la misma modalidad de entrada: los Hospitales 1 y 2 disponen de imágenes FLAIR, mientras que los Hospitales 3 y 4 trabajan con imágenes T1w. Esta separación induce un problema de *domain shift*, donde cada cliente observa la misma tarea clínica desde distribuciones visuales distintas.

Se implementó una arquitectura basada en ResNet-18 adaptada a imágenes en escala de grises y se compararon dos estrategias federadas: FedAvg, con agregación por media simple, y FedProx, con penalización proximal. Además del valor principal $\mu = 0,01$, se evaluaron $\mu = 0,001$ y $\mu = 0,1$ para analizar la sensibilidad del método. La simulación se realizó con *Flower* y *Ray* en un entorno WSL2, simulando cuatro clientes sobre una GPU NVIDIA RTX 4060. También se añadieron baselines centralizados y local-only, junto con métricas a nivel de corte axial y a nivel de paciente. Los resultados muestran que el entrenamiento federado mejora claramente la transferencia entre modalidades frente a modelos entrenados en una sola modalidad. En la ejecución final, FedProx con $\mu = 0,01$ obtuvo el mejor F1-score global por slice, mientras que FedAvg, FedProx con $\mu = 0,001$ y FedProx con $\mu = 0,01$ alcanzaron F1 perfecto a nivel de paciente.

Palabras clave: aprendizaje federado, Federated Transfer Learning, Esclerosis Múltiple, MRI, FLAIR, T1w, ResNet-18, Flower, Ray.

1. INTRODUCCIÓN

La Esclerosis Múltiple (EM) es una enfermedad desmielinizante del sistema nervioso central cuyo diagnóstico y seguimiento clínico dependen en gran medida del análisis de imágenes de resonancia magnética (MRI). En este contexto, los modelos de aprendizaje profundo pueden ayudar a extraer patrones visuales asociados a la enfermedad y a construir sistemas de apoyo a la decisión clínica. Sin embargo, el

entrenamiento de redes neuronales profundas requiere conjuntos de datos amplios, variados y representativos, algo difícil de conseguir en entornos médicos reales.

La centralización de datos clínicos procedentes de múltiples hospitales está limitada por restricciones legales, éticas y técnicas. Normativas como el RGPD en Europa o HIPAA en Estados Unidos restringen la transferencia de información sensible de pacientes. El Aprendizaje Federado (AF) surge como una alternativa a este problema: los datos permanecen en cada institución y únicamente se comparten actualizaciones del modelo, como pesos o gradientes [1]. Así, varios centros pueden colaborar en el entrenamiento de un modelo común sin compartir directamente las imágenes originales.

No obstante, los entornos multicentro presentan una dificultad adicional: no todos los hospitales adquieren o comparten las mismas modalidades de imagen. Este proyecto estudia un caso de *Federated Transfer Learning* (FTL), donde los hospitales colaboran para resolver una tarea común, EM frente a control, pero no todos observan el problema desde el mismo espacio de características. En concreto, los Hospitales 1 y 2 trabajan exclusivamente con imágenes FLAIR, mientras que los Hospitales 3 y 4 trabajan con imágenes T1w.

Las secuencias FLAIR y T1w presentan distribuciones de intensidad y contraste diferentes. FLAIR permite resaltar ciertas alteraciones asociadas a lesiones al suprimir la señal del líquido cefalorraquídeo, mientras que T1w ofrece una representación anatómica estructural distinta. Esta diferencia introduce un claro *domain shift*: un modelo entrenado únicamente con una modalidad puede no generalizar de forma directa a la otra.

El objetivo de este trabajo es analizar si un sistema federado puede aprender una representación útil para una tarea clínica común cuando cada cliente dispone de una modalidad distinta. Para ello, se implementa un pipeline de simulación federada con *Flower* [4] y *Ray* [5], usando una ResNet-18 [2] adaptada a imágenes médicas en escala de grises. Se comparan dos estrategias de agregación: FedAvg [1] y FedProx [3], esta última diseñada para mejorar la estabilidad en escenarios heterogéneos. Para completar la evaluación, se incorporan baselines centralizados y local-only que

permiten medir la ganancia real aportada por la colaboración federada.

1.1. Encuadre dentro del Aprendizaje Federado

El escenario planteado se sitúa entre el aprendizaje federado horizontal clásico y los enfoques de transferencia federada. En el aprendizaje federado horizontal, todos los clientes comparten el mismo espacio de características y la misma tarea, pero poseen subconjuntos diferentes de pacientes. En cambio, en este proyecto la tarea y el espacio de etiquetas son comunes, ya que todos los hospitales predicen EM frente a control, pero la distribución de entrada cambia de forma estructural por la modalidad MRI disponible en cada centro. Esta diferencia hace que las actualizaciones locales no sean intercambiables de forma ideal, porque cada cliente optimiza el modelo bajo una apariencia visual distinta del mismo fenómeno clínico.

Desde una perspectiva estricta de taxonomías federadas, el problema no corresponde a una configuración vertical clásica, ya que no existen pacientes alineados entre hospitales ni cada institución aporta variables complementarias del mismo sujeto. Tampoco es un caso horizontal IID, porque los hospitales FLAIR y T1w no observan la misma distribución de intensidades, contraste ni textura. Por ello, el proyecto se interpreta como un caso práctico de *Federated Transfer Learning* orientado a transferencia entre dominios: el conocimiento aprendido en una modalidad debe contribuir a mejorar una representación global que también sea útil en la otra.

Esta distinción es importante para interpretar los resultados. Un rendimiento elevado no implica que FLAIR y T1w sean equivalentes, sino que la arquitectura y el procedimiento federado han sido capaces de extraer patrones discriminativos suficientemente estables para la tarea definida. En otras palabras, el objetivo no es aprender un clasificador especializado por modalidad, sino comprobar si la colaboración federada permite construir una solución común ante un cambio de dominio controlado.

2. FORMULACIÓN DEL PROBLEMA

El problema se formula como una red de aprendizaje federado compuesta por cuatro nodos cliente y un servidor central. Cada nodo representa un hospital que posee datos locales de pacientes, pero que no puede compartir directamente sus imágenes MRI por razones de privacidad, regulación y gobernanza de datos clínicos. El servidor no accede a las imágenes ni a las etiquetas individuales, sino únicamente a los parámetros del modelo enviados por los clientes tras cada fase de entrenamiento local.

Formalmente, se considera un conjunto de clientes $\mathcal{K} = \{1, 2, 3, 4\}$. Cada cliente k dispone de un conjunto local de datos $\mathcal{D}_k = \{(x_i, y_i)\}_{i=1}^{n_k}$, donde x_i es un

corte axial MRI y $y_i \in \{0, 1\}$ indica si el paciente corresponde a un control sano o a un caso de EM. La distribución de los datos no es idéntica entre clientes, ya que $\mathcal{D}_1$ y $\mathcal{D}_2$ contienen imágenes FLAIR, mientras que $\mathcal{D}_3$ y $\mathcal{D}_4$ contienen imágenes T1w. Por tanto, aunque todos los clientes comparten la misma tarea de clasificación, no comparten exactamente el mismo dominio visual.

Cada hospital entrena una copia local de un modelo paramétrico f_w , implementado mediante una ResNet-18 adaptada a imágenes de un canal. Para una muestra x_i , el modelo produce una distribución de probabilidad sobre las dos clases mediante una capa final de clasificación. La función de pérdida local se define como la entropía cruzada media sobre los datos del cliente:

$$F_k(w) = \frac{1}{n_k} \sum_{i=1}^{n_k} \ell(f_w(x_i), y_i), \quad (1)$$

donde $\ell(\cdot)$ representa la pérdida de entropía cruzada. El objetivo federado global consiste en aprender unos parámetros w que minimicen el rendimiento agregado sobre todos los hospitales, sin mover los datos locales fuera de cada institución:

$$\min_w F(w) = \frac{1}{K} \sum_{k=1}^K F_k(w). \quad (2)$$

En este proyecto se emplea una agregación uniforme entre clientes, por lo que todos los hospitales tienen el mismo peso en la optimización global. Esta elección es coherente con el objetivo de evitar que una modalidad domine sobre la otra por tener un número ligeramente mayor de cortes. Desde el punto de vista de la red, las aristas conectan cada hospital con el servidor central y representan el intercambio de parámetros del modelo, no la transferencia de datos clínicos. No se definen conexiones directas entre hospitales, ya que la comunicación se realiza exclusivamente mediante el servidor federado.

La heterogeneidad principal del problema procede del cambio de modalidad FLAIR/T1w. Esto convierte la tarea en un caso práctico de *Federated Transfer Learning*: los clientes colaboran para resolver una tarea común, pero las representaciones locales se aprenden a partir de distribuciones de entrada diferentes. En consecuencia, el modelo global debe capturar patrones asociados a la EM que sean suficientemente robustos para generalizar entre modalidades.

3. METODOLOGÍA

La metodología se diseñó para reproducir un escenario multicentro realista, donde los hospitales colaboran sin compartir datos crudos y donde la heterogeneidad principal no proviene de la proporción de clases, sino de la modalidad de imagen disponible en cada centro.

3.1. Arquitectura Federada

El sistema se modeló como una red federada en topología de estrella. Cada hospital actúa como cliente y entrena localmente una copia del modelo con sus propios datos. El servidor central recibe los pesos actualizados, realiza la agregación y redistribuye el modelo global para la siguiente ronda.

La simulación se ejecutó con *Flower*, framework especializado en aprendizaje federado, y *Ray*, utilizado como backend para la ejecución concurrente de clientes. El entorno de ejecución fue WSL2 sobre una máquina local con GPU NVIDIA RTX 4060. Para simular cuatro clientes sobre una única GPU se configuró una asignación fraccionada de recursos, reservando aproximadamente 0.25 GPUs por cliente.




Fig. 1. Arquitectura federada empleada para transferir conocimiento entre hospitales FLAIR y T1w.

3.2. Justificación de una Red Federada Única

Una decisión metodológica relevante fue utilizar una única red federada con los cuatro hospitales, en lugar de construir dos redes independientes: una para FLAIR y otra para T1w. Aunque entrenar una red separada por modalidad podría acelerar la convergencia y mejorar el rendimiento local dentro de cada dominio, esta alternativa eliminaría precisamente el fenómeno que se desea estudiar.

El objetivo del proyecto es evaluar un escenario de *Federated Transfer Learning* ante un cambio de dominio entre modalidades. Por ello, es necesario que el modelo global reciba actualizaciones procedentes tanto de hospitales FLAIR como de hospitales T1w. Esta configuración obliga al sistema a buscar representaciones comunes de la tarea EM frente a control, en lugar de especializarse únicamente en un contraste de imagen concreto.

Desde un punto de vista clínico, esta decisión aproxima mejor un entorno multicentro real, donde no todos los hospitales disponen de los mismos protocolos de adquisición o de las mismas modalidades MRI. El escenario resultante es no-IID: los clientes no son independientes e idénticamente distribuidos, ya que observan distribuciones visuales distintas aunque compartan la misma tarea diagnóstica.

3.3. Partición de Datos

El conjunto de entrenamiento se dividió estrictamente por hospital y modalidad. Los Hospitales 1 y 2 contienen únicamente imágenes FLAIR, mientras que los Hospitales 3 y 4 contienen únicamente imágenes T1w. En total, el entrenamiento federado utilizó 148 pacientes y 13.468 cortes axiales. La distribución por hospital se resume en la table 1.

Table 1. Distribución de pacientes y cortes de entrenamiento por hospital.

Hospital	Modalidad	Pacientes	EM	Control	Slices EM	Slices control
1	FLAIR	38	23	15	2093	1365
2	FLAIR	37	22	15	2002	1365
3	T1w	37	22	15	2002	1365
4	T1w	36	22	14	2002	1274

Además, se reservó un conjunto `global_test.csv` independiente para la evaluación centralizada del modelo global. Este conjunto no comparte pacientes con los datos de entrenamiento, por lo que actúa como test holdout. Durante el desarrollo también se corrigió la partición local de validación para evitar fugas entre cortes del mismo paciente: los splits locales se realizan por `patient_id`, no por imagen individual.




Fig. 2. Distribución de cortes por hospital y clase.




Fig. 3. Distribución de cortes por modalidad y clase.

3.4. Preprocesado y Control de Fugas de Datos

Todas las imágenes se cargaron como cortes axiales bidimensionales en escala de grises. Antes de introducirlas en la red, cada imagen se redimensionó a 224×224 píxeles para hacerla compatible con la arquitectura ResNet-18. Posteriormente se transformó a

tensor y se normalizó con media 0,5 y desviación típica 0,5, de modo que los valores de intensidad quedan centrados alrededor de cero. Este preprocesado es sencillo, reproducible y común para todos los clientes, evitando introducir transformaciones distintas por modalidad que pudieran actuar como una fuente adicional de sesgo experimental.

No se aplicaron aumentos de datos en los experimentos finales. Esta decisión mantiene el análisis centrado en el efecto de la agregación federada y del cambio de modalidad FLAIR/T1w. Aunque técnicas como rotaciones leves, recortes o perturbaciones de intensidad podrían mejorar la robustez, también podrían modificar de forma desigual la apariencia de cada modalidad y dificultar la interpretación directa de la comparativa entre FedAvg y FedProx.

Un aspecto crítico del pipeline fue evitar fugas entre entrenamiento y validación local. Dado que un mismo paciente aporta múltiples cortes axiales, una partición aleatoria por imagen podría situar cortes del mismo sujeto tanto en entrenamiento como en validación. Esto inflaría artificialmente el rendimiento local, ya que los cortes cercanos de un mismo volumen comparten información anatómica y patrones de intensidad. Para evitarlo, los splits locales se realizaron por `patient_id`, manteniendo todos los cortes de un paciente dentro de la misma partición.

La evaluación principal se realizó sobre `global_test.csv`, un conjunto holdout sin solape de pacientes con los hospitales de entrenamiento. Las métricas reportadas en resultados son métricas a nivel de corte y a nivel de paciente. Para obtener la evaluación por paciente, se promedian las probabilidades de clase EM de todos los cortes axiales del mismo sujeto y se aplica un umbral de 0.5. Esta agregación permite comprobar si los errores aislados por slice afectan realmente a la decisión diagnóstica global del paciente.

3.5. Definición de la Tarea

La tarea definida en el proyecto es clasificación binaria EM frente a control. Por tanto, la etiqueta empleada durante el entrenamiento procede de la columna `label_id` de los ficheros CSV:

- 0: control sano.
- 1: paciente con EM.

Aunque el dataset contiene máscaras asociadas a algunas imágenes, estas no se utilizan para redefinir la tarea como lesión visible frente a tejido sano. Esta decisión es importante, ya que el objetivo del proyecto es comparar modalidades en un escenario FTL de clasificación EM vs control.

3.6. Modelo Local y Optimizador

Cada cliente entrena localmente una ResNet-18 [2]. Esta arquitectura se eligió por su equilibrio entre

capacidad de representación y coste computacional. Al tratarse de imágenes MRI en escala de grises, la primera capa convolucional se modificó para aceptar un único canal de entrada en lugar de los tres canales RGB habituales. La última capa totalmente conectada se reemplazó por una capa de salida de dos clases.

La elección de ResNet-18 responde a tres criterios. En primer lugar, su profundidad moderada reduce el riesgo de sobreajuste en un conjunto de datos médico de tamaño limitado. En segundo lugar, tiene un número de parámetros menor que arquitecturas más profundas, lo que reduce el coste de comunicación en el escenario federado. En tercer lugar, sus conexiones residuales facilitan la optimización y permiten entrenar modelos convolucionales suficientemente expresivos sin aumentar en exceso la complejidad.

El modelo se inicializó a partir de la arquitectura ResNet-18 disponible en `torchvision`, adaptando la primera convolución mediante el promedio de los pesos preentrenados de los tres canales RGB. Esta estrategia permite aprovechar representaciones visuales generales aprendidas previamente y ajustarlas al dominio médico.

Como optimizador local se utilizó Adam. Su uso se justifica por el empleo de tasas de aprendizaje adaptativas, que favorecen una convergencia inicial rápida y ayudan a estabilizar el entrenamiento local cuando cada cliente dispone de un subconjunto limitado y sesgado por modalidad. En todos los experimentos finales se empleó un *learning rate* de 10^{-4} .

3.7. Adaptación de ResNet-18 a Imagen Médica Monocanal

La ResNet-18 original está definida para imágenes RGB de tres canales. En este proyecto, las imágenes MRI se procesan como imágenes monocanal, por lo que fue necesario modificar la primera convolución de la red. En lugar de inicializar dicha capa completamente desde cero, se aprovecharon los pesos preentrenados disponibles en `torchvision`. La adaptación se realizó promediando los pesos RGB originales:

$$W_{o,1,u,v}^{gray} = \frac{1}{3} \sum_{c=1}^3 W_{o,c,u,v}^{rgb}, \quad (3)$$

donde W^{rgb} representa los pesos de la primera convolución preentrenada, c indexa los canales RGB, o indexa el filtro de salida y (u, v) la posición espacial del kernel. De esta forma, la red conserva filtros de bajo nivel útiles, como detectores de bordes y texturas, pero queda adaptada a la entrada de un único canal.

La última capa totalmente conectada se reemplazó por una capa lineal con dos salidas, correspondientes a control y EM. El resto de la red se entrenó de forma federada en todos los clientes. Esta estrategia combina transferencia previa desde ImageNet con transferencia federada entre modalidades MRI. Aunque ImageNet

no pertenece al dominio médico, sus filtros iniciales pueden servir como punto de partida estable cuando el número de pacientes es limitado.

3.8. Algoritmos Federados

3.8.1. FedAvg con Media Simple

El algoritmo FedAvg agrega los modelos locales en cada ronda para producir un nuevo modelo global [1]. En este proyecto se empleó una variante de media simple, sin ponderar por el número de muestras de cada hospital:

$$w^{t+1} = \frac{1}{K} \sum_{k=1}^K w_k^{t+1}, \quad (4)$$

donde $K = 4$ es el número de clientes. Esta decisión se tomó para evitar que un hospital o modalidad con más cortes tuviera más influencia en la agregación global.

En escenarios heterogéneos, FedAvg puede sufrir oscilaciones debido a que cada cliente optimiza el modelo hacia su propio dominio local. En este proyecto, dicha heterogeneidad aparece por la separación FLAIR/T1w. No obstante, los resultados muestran que la media simple fue una línea base muy competitiva y alcanzó un rendimiento muy alto tanto por slice como por paciente.

3.8.2. FedProx

FedProx introduce una penalización proximal en el entrenamiento local para reducir la divergencia entre el modelo de cada cliente y el modelo global [3]. La función objetivo local queda definida como:

$$\min_w \left(F_k(w) + \frac{\mu}{2} \|w - w^t\|^2 \right), \quad (5)$$

donde $F_k(w)$ es la pérdida local del cliente k , w^t son los pesos globales al inicio de la ronda y μ controla la fuerza de la regularización.

La intuición de FedProx es limitar cuánto puede alejarse cada hospital del modelo global durante su entrenamiento local. Así, se evita que un cliente sesgue excesivamente la red hacia las características propias de su modalidad. En los experimentos finales se utilizó $\mu = 0,01$ como configuración principal y se añadieron dos valores adicionales, $\mu = 0,001$ y $\mu = 0,1$, para comprobar si una regularización menor o mayor modificaba el equilibrio entre adaptación local y estabilidad global.

3.9. Flujo de Entrenamiento Federado

El entrenamiento se ejecutó por rondas síncronas. Al inicio de cada ronda, el servidor distribuye el modelo global actual a los cuatro hospitales. Cada cliente reemplaza sus parámetros locales por los recibidos, entrena durante dos épocas sobre sus datos privados y

devuelve al servidor los pesos actualizados. El servidor agrega los modelos locales mediante media simple y evalúa el modelo resultante sobre el test global.

Algorithm 1 Entrenamiento federado síncrono empleado en el proyecto

```

1: Inicializar modelo global  $w^0$ 
2: for ronda  $t = 0, \dots, T - 1$  do
3:   for cada cliente  $k \in \{1, 2, 3, 4\}$  en paralelo do
4:     Recibir pesos globales  $w^t$ 
5:     Entrenar localmente durante  $E = 2$  épocas con Adam
6:     if estrategia = FedProx then
7:       Optimizar  $F_k(w) + \frac{\mu}{2} \|w - w^t\|^2$ 
8:     else
9:       Optimizar  $F_k(w)$ 
10:    end if
11:    Enviar pesos locales  $w_k^{t+1}$  al servidor
12:  end for
13:  Agregar  $w^{t+1} = \frac{1}{4} \sum_{k=1}^4 w_k^{t+1}$ 
14:  Evaluar  $w^{t+1}$  sobre global_test.csv
15: end for

```

Este flujo reproduce la restricción fundamental del aprendizaje federado: los datos no abandonan el hospital. Lo único que se comunica son parámetros del modelo. En la simulación, los cuatro clientes se ejecutan sobre una única máquina, pero el patrón de comunicación implementado es equivalente al de un servidor federado que coordina hospitales separados.

3.10. Configuración Experimental

Los experimentos principales se ejecutaron durante 10 rondas federadas. En cada ronda, los cuatro clientes participaron tanto en entrenamiento como en evaluación. La configuración común fue:

- Modelo: ResNet-18 adaptada a 1 canal.
- Número de clientes: 4.
- Rondas federadas: 10.
- Épocas locales por ronda: 2.
- Optimizador: Adam.
- Learning rate: 10^{-4} .
- Batch size: 32.
- Evaluación principal: test centralizado `global_test.csv`.

Las métricas reportadas son exactitud, F1-score ponderado, sensibilidad y especificidad. En un contexto clínico, la sensibilidad es especialmente relevante porque mide la capacidad de detectar correctamente los casos de EM, mientras que la especificidad cuantifica la capacidad de no clasificar controles sanos como patológicos.

Para completar la evaluación se añadieron baselines centralizados y local-only. El baseline centralizado entrena con todos los datos juntos, sin restricción federada, y funciona como cota superior experimental. Los baselines local-only se entrenan únicamente con FLAIR, únicamente con T1w o con un hospital aislado. Todos los baselines se entrenaron durante 20 épocas, equivalentes a las 10 rondas federadas con 2 épocas locales por ronda.

3.11. Métricas de Evaluación

La evaluación se basó en cuatro métricas complementarias. La exactitud mide la proporción total de predicciones correctas, mientras que el F1-score ponderado resume precisión y sensibilidad teniendo en cuenta el soporte de cada clase. Además, se reportaron sensibilidad y especificidad por su interpretación directa en un contexto clínico.

Sea TP el número de casos EM correctamente clasificados, TN el número de controles correctamente clasificados, FP los controles clasificados como EM y FN los casos EM clasificados como control. La sensibilidad y la especificidad se calcularon como:

$$\text{Sensibilidad} = \frac{TP}{TP + FN}, \quad (6)$$

$$\text{Especificidad} = \frac{TN}{TN + FP}. \quad (7)$$

La sensibilidad es especialmente relevante porque penaliza los falsos negativos, es decir, pacientes con EM que el modelo no detecta. La especificidad, por otro lado, mide la capacidad de evitar falsos positivos en controles sanos. Reportar ambas métricas permite comprobar si un modelo alcanza alto rendimiento global a costa de favorecer una clase concreta.

Además de las métricas por slice, se reportan métricas a nivel de paciente. En este caso, las probabilidades de clase EM de los cortes de un mismo paciente se promedian y posteriormente se aplica un umbral de 0.5. Esta segunda evaluación es importante porque reduce el efecto de errores aislados por corte y se aproxima mejor a una decisión diagnóstica por sujeto.

4. RESULTADOS EXPERIMENTALES

Esta sección presenta los resultados obtenidos sobre el conjunto `global_test.csv`. Este conjunto se mantuvo separado de los datos de entrenamiento y no comparte pacientes con los clientes federados. Por tanto, las métricas centralizadas reflejan la capacidad de generalización del modelo global agregado.

4.1. Baselines

La table 2 resume los baselines añadidos. El modelo centralizado alcanza rendimiento perfecto, lo que representa una cota superior sin restricción federada. En

cambio, los modelos entrenados únicamente con una modalidad muestran una caída clara al evaluar sobre el test global completo. Este resultado confirma que el cambio FLAIR/T1w introduce una transferencia no trivial.

Table 2. Baselines sobre `global_test.csv`. Se reportan F1 por slice y por paciente.

Baseline	Pacientes train	F1 slice	F1 paciente	Sens. / Esp. paciente
Centralizado	148	1.0000	1.0000	1.0000 / 1.0000
Local-only FLAIR	75	0.7786	0.7393	1.0000 / 0.5385
Local-only T1w	73	0.7266	0.7266	0.4545 / 1.0000
Hospital 1 FLAIR	30	0.7725	0.7393	1.0000 / 0.5385
Hospital 2 FLAIR	29	0.8954	0.9584	1.0000 / 0.9231
Hospital 3 T1w	29	0.7266	0.7266	0.4545 / 1.0000
Hospital 4 T1w	28	0.7266	0.7266	0.4545 / 1.0000

El análisis por modalidad muestra el mismo patrón. El baseline `local-only FLAIR` consigue F1 de paciente 1.0000 en FLAIR, pero baja a 0.2841 en T1w. De forma simétrica, `local-only T1w` consigue F1 de paciente 1.0000 en T1w, pero baja a 0.3769 en FLAIR. Por tanto, los modelos especializados aprenden bien su propio dominio, pero no resuelven de forma adecuada la transferencia entre modalidades.

4.2. Resultados Globales

La table 3 muestra el rendimiento final tras 10 rondas. En la ejecución final, FedProx con $\mu = 0,01$ obtuvo el mejor resultado global por slice, con F1-score de 0.9924. FedAvg y FedProx con $\mu = 0,001$ quedaron prácticamente empatados, mientras que $\mu = 0,1$ redujo el rendimiento por ser una regularización más restrictiva.

Table 3. Resultados globales sobre `global_test.csv` tras 10 rondas federadas.

Estrategia	Ronda	Loss	Acc. slice	F1 slice	F1 paciente	Sens. / Esp. slice
FedAvg	10	0.0426	0.9892	0.9892	1.0000	0.9780 / 0.9987
FedProx ($\mu = 0,001$)	10	0.0303	0.9892	0.9892	1.0000	0.9975 / 0.9822
FedProx ($\mu = 0,01$)	10	0.0223	0.9924	0.9924	1.0000	0.9885 / 0.9958
FedProx ($\mu = 0,1$)	10	0.0749	0.9755	0.9755	0.9791	0.9560 / 0.9920

También se analizó la mejor ronda alcanzada por cada estrategia según el F1-score global por slice. En el caso de FedAvg, el mejor resultado aparece en la ronda 9. En el caso de FedProx con $\mu = 0,01$, el mejor resultado coincide con la ronda final.

Table 4. Mejor ronda observada según F1-score global por slice.

Estrategia	Mejor ronda	Loss	Accuracy	F1	Sens. / Esp.
FedAvg	9	0.0202	0.9929	0.9929	0.9875 / 0.9975
FedProx ($\mu = 0,001$)	9	0.0310	0.9899	0.9899	0.9870 / 0.9924
FedProx ($\mu = 0,01$)	10	0.0223	0.9924	0.9924	0.9885 / 0.9958
FedProx ($\mu = 0,1$)	7	0.0637	0.9773	0.9773	0.9600 / 0.9920

4.3. Evolución por Rondas

Las curvas de la fig. 4 y la fig. 5 muestran la evolución del rendimiento global. Las estrategias con $\mu =$

0,001 y $\mu = 0,01$ se mantienen competitivas frente a FedAvg. En cambio, $\mu = 0,1$ queda por debajo, lo que sugiere que una penalización proximal demasiado fuerte limita la adaptación local necesaria para este problema.




Fig. 4. Evolución del F1-score global por slice durante las 10 rondas federadas.




Fig. 5. Evolución de la exactitud global por slice durante las 10 rondas federadas.

La fig. 6 muestra la evolución del F1-score a nivel de paciente. Esta métrica es más estable porque agrega la evidencia de todos los cortes de cada sujeto. FedAvg, FedProx con $\mu = 0,001$ y FedProx con $\mu = 0,01$ alcanzan F1 de paciente 1.0000 al final del entrenamiento.




Fig. 6. Evolución del F1-score global a nivel de paciente durante las 10 rondas federadas.

4.4. Análisis de Estabilidad

La evolución por rondas muestra que todos los métodos federados mejoran rápidamente tras recibir las primeras actualizaciones locales. En la ronda 0,

correspondiente al modelo inicial antes del entrenamiento federado efectivo, el rendimiento global es bajo y está dominado por un desequilibrio claro entre sensibilidad y especificidad. Tras las primeras rondas, el modelo ya incorpora información discriminativa de los cuatro hospitales y el F1-score global aumenta de forma notable.

En FedAvg, la mejor ronda por slice se alcanza en la ronda 9 con F1 de 0.9929, mientras que la ronda 10 termina ligeramente por debajo, con F1 de 0.9892. Esto indica que, aunque la media simple es muy competitiva, sigue habiendo cierta oscilación por la heterogeneidad de modalidad. FedProx con $\mu = 0,01$ muestra un comportamiento más favorable en la última ronda, alcanzando F1 de 0.9924 y la menor pérdida final entre las estrategias federadas.

El valor $\mu = 0,1$ alcanza su mejor ronda antes, en la ronda 7, y después no mejora. Este comportamiento sugiere que una regularización proximal excesiva puede impedir que los clientes se adapten lo suficiente a sus distribuciones locales. En cambio, $\mu = 0,001$ y $\mu = 0,01$ mantienen un equilibrio más adecuado entre estabilidad global y aprendizaje local.

4.5. Resultados por Modalidad

La table 5 muestra los resultados finales separados por modalidad. El mejor resultado por slice en FLAIR lo obtiene FedProx con $\mu = 0,001$, mientras que el mejor resultado por slice en T1w lo obtiene FedAvg. La configuración $\mu = 0,01$ ofrece el mejor equilibrio global entre ambas modalidades.

Table 5. Resultados finales por modalidad a nivel de slice tras 10 rondas.

Estrategia	Modalidad	Accuracy	F1	Sens.	Esp.
FedAvg	FLAIR	0.9814	0.9814	0.9597	1.0000
FedAvg	T1w	0.9985	0.9985	1.0000	0.9973
FedProx ($\mu = 0,001$)	FLAIR	0.9979	0.9979	0.9954	1.0000
FedProx ($\mu = 0,001$)	T1w	0.9790	0.9791	1.0000	0.9615
FedProx ($\mu = 0,01$)	FLAIR	0.9903	0.9903	0.9789	1.0000
FedProx ($\mu = 0,01$)	T1w	0.9950	0.9950	1.0000	0.9908
FedProx ($\mu = 0,1$)	FLAIR	0.9628	0.9626	0.9194	1.0000
FedProx ($\mu = 0,1$)	T1w	0.9905	0.9905	1.0000	0.9826

A nivel de paciente, FedAvg, FedProx con $\mu = 0,001$ y FedProx con $\mu = 0,01$ alcanzan F1 de 1.0000 tanto en FLAIR como en T1w. La única configuración federada que no llega a rendimiento perfecto por paciente es $\mu = 0,1$, con F1 de 0.9614 en FLAIR y 1.0000 en T1w.

4.6. Resultados por Hospital

La evaluación por hospital permite comprobar si el modelo global favorece de forma excesiva a algún cliente concreto. Como se muestra en la table 6, las diferencias más visibles aparecen en los hospitales FLAIR, especialmente en el Hospital 1. Aun así, para FedAvg y FedProx con $\mu = 0,01$, todos los hospitales alcanzan F1 de paciente 1.0000.




Fig. 7. Comparación final del F1-score por modalidad de imagen.

Table 6. Resultados finales por hospital a nivel de slice tras 10 rondas.

Estrategia	Hospital	Accuracy	F1	Sens.	Esp.
FedAvg	H1 (FLAIR)	0.9687	0.9686	0.9322	1.0000
FedAvg	H2 (FLAIR)	0.9941	0.9941	0.9872	1.0000
FedAvg	H3 (T1w)	0.9970	0.9970	1.0000	0.9945
FedAvg	H4 (T1w)	1.0000	1.0000	1.0000	1.0000
FedProx ($\mu = 0,01$)	H1 (FLAIR)	0.9806	0.9805	0.9579	1.0000
FedProx ($\mu = 0,01$)	H2 (FLAIR)	1.0000	1.0000	1.0000	1.0000
FedProx ($\mu = 0,01$)	H3 (T1w)	0.9900	0.9900	1.0000	0.9817
FedProx ($\mu = 0,01$)	H4 (T1w)	1.0000	1.0000	1.0000	1.0000

4.7. Discusión

Los resultados confirman que el aprendizaje federado es capaz de construir un modelo global efectivo incluso cuando los clientes observan modalidades MRI distintas. La separación estricta entre FLAIR y T1w no impidió la convergencia del sistema. Esto sugiere que la ResNet-18 aprende representaciones visuales útiles para la clasificación EM vs control que no dependen únicamente de la modalidad concreta.

Los baselines local-only muestran que entrenar en una sola modalidad no resuelve adecuadamente la transferencia entre FLAIR y T1w. El baseline FLAIR funciona bien en pacientes FLAIR, pero su F1 de paciente cae a 0.2841 en T1w. De forma simétrica, el baseline T1w alcanza F1 perfecto en T1w, pero baja a 0.3769 en FLAIR. Esta diferencia confirma que el problema no es trivial y que la colaboración entre modalidades aporta información útil.

Contra la expectativa inicial de que FedProx pudiera superar claramente a FedAvg en un entorno heterogéneo, los resultados muestran una comparación más matizada. FedAvg sigue siendo una línea base muy fuerte, pero FedProx con $\mu = 0,01$ obtiene el mejor F1-score final por slice y mantiene rendimiento perfecto a nivel de paciente. En cambio, $\mu = 0,1$ parece excesivo para este escenario, ya que limita demasiado la adaptación local y reduce el F1 global final.

La diferencia entre métricas por slice y por paciente también es relevante. A nivel de slice aún aparecen errores aislados, especialmente en FLAIR, pero al agregar la evidencia de todos los cortes de un paciente, los métodos federados principales clasifican correctamente todos los sujetos del test global. Esto sugiere

que parte de los errores por corte no alteran la decisión diagnóstica agregada.

5. LIMITACIONES Y AMENAZAS A LA VALIDEZ

Aunque los resultados obtenidos son elevados, deben interpretarse con cautela. En primer lugar, las métricas por slice y por paciente tienen interpretaciones distintas. El split por paciente evita fugas directas entre entrenamiento y test, pero varios cortes de un mismo paciente siguen estando correlacionados dentro de cada partición. La evaluación por paciente reduce este problema agregando predicciones, pero no sustituye una validación externa con sujetos de otro centro real.

En segundo lugar, el estudio se limita a dos modalidades, FLAIR y T1w, y a cuatro clientes simulados. Esto permite aislar el efecto del cambio de modalidad, pero no cubre toda la heterogeneidad presente en un entorno clínico real, donde también aparecen diferencias por escáner, protocolo de adquisición, resolución, centro, población y calidad de anotación. Una evaluación externa en datos procedentes de otra institución sería necesaria para estimar mejor la generalización fuera del dominio simulado.

Otra limitación es que no se incorporaron mecanismos criptográficos ni privacidad diferencial. El aprendizaje federado evita mover las imágenes originales, pero las actualizaciones del modelo pueden contener información sensible si un atacante aplica técnicas avanzadas de inversión o inferencia. En un despliegue clínico real, el pipeline debería complementarse con agregación segura, control de acceso, auditoría y, en función del caso, privacidad diferencial.

Finalmente, aunque se añadió un pequeño barido de μ para FedProx, no se realizó una búsqueda exhaustiva de hiperparámetros. Parámetros como el número de épocas locales, el learning rate, el tamaño de batch o el uso de capas de normalización locales podrían modificar el equilibrio entre convergencia global y especialización por modalidad.

6. CONCLUSIONES

Este proyecto ha validado empíricamente la viabilidad de un sistema de *Federated Transfer Learning* para clasificación EM frente a control en un escenario multicentro heterogéneo. La principal dificultad del problema no estaba en una distribución de clases extremadamente desigual, sino en la diferencia de modalidad entre hospitales: FLAIR en los Hospitales 1 y 2, y T1w en los Hospitales 3 y 4.

Los baselines confirman la necesidad de colaboración: los modelos local-only funcionan bien en su propia modalidad, pero generalizan mal a la modalidad no vista. Frente a ello, los modelos federados combinan información de ambos dominios y logran un ren-

dimiento mucho más equilibrado. En la ejecución final, FedProx con $\mu = 0,01$ obtuvo el mejor F1-score global por slice, con 0.9924, mientras que FedAvg, FedProx con $\mu = 0,001$ y FedProx con $\mu = 0,01$ alcanzaron F1 de paciente 1.0000.

La comparativa permite concluir que FedAvg es una línea base muy competitiva, pero que FedProx puede aportar una mejora cuando el valor de μ está bien ajustado. En este escenario, $\mu = 0,01$ ofrece el mejor equilibrio entre estabilidad global y adaptación local, mientras que $\mu = 0,1$ resulta demasiado restrictivo.

A nivel de ingeniería, el pipeline implementado con *Flower*, *Ray* y PyTorch permitió simular cuatro hospitales sobre una única GPU, controlar el reparto de recursos y registrar métricas globales por ronda. Además, se corrigieron aspectos críticos para la validez experimental, como el uso de etiquetas EM/control desde CSV, el split local por paciente, la evaluación centralizada sobre un test sin solape de pacientes, la evaluación agregada por paciente y la comparación contra baselines centralizados y local-only.

Como trabajo futuro, sería recomendable estudiar técnicas de personalización federada, como mantener las capas de *Batch Normalization* locales para absorber sesgos propios de cada modalidad o escáner. También resultaría interesante incorporar Grad-CAM para analizar la interpretabilidad clínica de las predicciones y añadir mecanismos de privacidad diferencial sobre las actualizaciones locales.

7. REFERENCES

- [1] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, y B. A. y. Arcas, *Communication-Efficient Learning of Deep Networks from Decentralized Data*, AISTATS, 2017. <https://arxiv.org/abs/1602.05629>
- [2] K. He, X. Zhang, S. Ren, y J. Sun, *Deep Residual Learning for Image Recognition*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016. <https://arxiv.org/abs/1512.03385>
- [3] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar, y V. Smith, *Federated Optimization in Heterogeneous Networks*, Proceedings of Machine Learning and Systems, vol. 2, pp. 429–450, 2020. <https://arxiv.org/abs/1812.06127>
- [4] D. J. Beutel, T. Topal, A. Mathur, et al., *Flower: A Friendly Federated Learning Research Framework*, arXiv preprint, 2020. <https://arxiv.org/abs/2007.14390>
- [5] P. Moritz, R. Nishihara, S. Wang, et al., *Ray: A Distributed Framework for Emerging AI Applications*, 13th USENIX Symposium on Operating Systems Design and Implementation (OSDI), 2018. <https://arxiv.org/abs/1712.05866>
- [6] Q. Yang, Y. Liu, T. Chen, y Y. Tong, *Federated Machine Learning: Concept and Applications*, ACM Transactions on Intelligent Systems and Technology, 10(2), pp. 1–19, 2019. <https://arxiv.org/abs/1902.04885>
- [7] PyTorch, *Torchvision ResNet Models Documentation*. <https://pytorch.org/vision/stable/models/resnet.html>